bc0a9ffd3135e4e91HZ83NS7EVBTwoW_WP2bWOKql_XUNRVq3A~~

杨元虎

男 | 33岁　13249456135　377862145@qq.com

13年工作经验 | 求职意向：AI大模型应用&全栈开发&研发效能 | 期望城市：深圳

个人优势

● 核心认证与大模型技术

○ 认证资质：HCIE-AI 解决方案架构师-专家、工信部-深度学习算法研发工程师-高级、智谱AI-大模型应用开发人才认证、PMP 项目管理认证

○ 个人荣誉：杉岩数据 2024 年度金牌员工、腾讯云 2020 年度效能优化之星

○ 大模型技术：RAG 检索增强、Agent 智能体、ReAct 范式、MCP 协议、BGE 嵌入/重排序模型、多模态检索、LoRA/QLoRA 微调、GPTQ/AWQ 量化、知识蒸馏、vLLM/LMDeploy 推理优化

○ 技术框架：PyTorch、TensorFlow、LangChain、Dify/FastGPT、LlamaIndex/Autogen

○ 模型部署：具备 DeepSeek、Qwen3、ChatGLM3、Baichuan2 等主流开源大模型 Ollama 私有化部署、昇腾 CANN/MindFormers/MindIE 部署适配、OpenAI API 全链路技术能力

● 开发与数据技术栈

○ 编程语言：Python、Golang、TypeScript/JavaScript、Shell/Bash

○ 开发框架：FastAPI、Gin/gRPC、Next.js/React、Agent SDK、Robot Framework

○ 数据存储：Milvus/Faiss/pgvector、PostgreSQL/MySQL、CTSDB 时序数据库、Neo4j 知识图谱

○ 机器学习：k-means 聚类、LightGBM/XGBoost 分类回归、iForest 异常检测、ARIMA 时序预测

○ 效率工具：Cursor 核心生产力、GitHub Copilot 源码研读、OpenClaw 创意创作、Claude Code持续关注

○ 基础服务：Nginx、Redis、Kafka、Zookeeper、ETCD、Ceph

● DevOps 云原生

○ 容器与编排：Podman/Docker Compose、Kubernetes、Helm、Kubeadm、Operator

○ 自动化工具：Jenkins、Ansible、CI/CD 流水线、Coding CI、ATDD

○ 监控与日志：Prometheus/Grafana、N9E、ELK、Fluentd、LangSmith

○ 基础设施：IaaS、Ubuntu/CentOS/openEuler/KylinOS/UOS、GPU、NPU、ARM 鲲鹏

● 行业解决方案与工程实践

○ AI 应用：iData 智能运维问答助手、AI 自动化测试平台、NPU 图片智能压缩、PB 级多模态检索模块、云服务器性能智能诊断引擎、iOS应用安全威胁感知平台

○ 性能优化：图片智能压缩优化、存储性能调优、CPU/NPU 异构算力协同优化、分布式训练推理性能调优、虚拟化性能调优、IaaS/PaaS/SaaS 全链路性能调优

○ 国产化适配：华为鲲鹏/昇腾 NPU 全栈适配、主流大模型国产化部署、国产化平台方案落地

○ 测试与交付：云服务器全维度性能基线测试、标准化性能测评体系建设、自动化测试体系全流程落地、端到端企业级私有化方案交付、DevOps 研发效能优化

工作经历

深圳市杉岩数据技术有限公司　AI研发效能（远程顾问）　2025.05-2026.02

1. 针对分布式存储测试场景，设计并落地专属的结构化知识库架构，将 Robot Framework 关键字库标准化重构并封装为智能体工具集，结合大模型 + RAG+LangGraph 实现测试用例智能生成、执行与缺陷闭环的全流程智能化升级。

2. 推动 Cursor 在企业内部落地，完成 AI 编程工具选型并输出标准化教程与最佳实践，面向研发团队开展专项培训。
3. 跟进大模型前沿技术迭代，输出技术调研与落地方案，为研发全流程提供AI技术咨询与支持。

深圳市杉岩数据技术有限公司 AI解决方案开发/研发效能 2022.06-2025.04

内容：

1. 负责 DevOps 全流程建设、推动研发模式从瀑布向敏捷转型、实践验收测试驱动开发（ATDD），包括搭建容器化编译环境、编写 K8S 集群一键部署工具、引入 N9E 重构监控告警模块、封装 Robot Framework Shell/API/CLI 关键字库等；
2. 负责 iData 智能运维问答助手从0到1落地，从告警精细化根因分析场景切入，逐步完成私有化问答系统、RAG检索体系、多角色权限隔离、智能体Agent、多模态检索全链路能力建设；完成 ChatGLM、Baichuan2 等主流大模型在华为 Atlas NPU 的全栈适配与性能优化，支撑 PB 级多模态数据检索。
3. 牵头 NPU 加速的智能图片压缩项目，基于 k-means 聚类算法构建图片压缩策略预测模型，设计分布式处理架构，开发 Golang 压缩 SDK 并完成存储网关对接；完成跨 NUMA 访问、CPU/NPU 算力协同等全链路性能调优，将核心推理环节卸载至 NPU 执行；
4. 跟进 AWS S3 MCP 规范，完成核心存储产品的 MCP 服务适配开发；持续跟进开源大模型迭代，完成适配测试与性能评估；基于大模型训练场景优化存储读写性能。

业绩：

1. 编译任务稳定性达到99.5%、支撑10+核心模块每日数百次集成编译，编译环境交付周期缩短至分钟级、集群部署周期在2小时内，封装核心关键字1000+、覆盖全量核心测试场景；
2. 智能运维问答助手落地10+私有化客户，运维故障排查效率提升85%，一线人员问题自主解决率从60%提升至95%，形成国产化部署最佳实践白皮书，支撑AI产品商业化推广；
3. 智能图片压缩方案在视觉无损前提下，压缩率提升12%，处理效率提升30倍，单集群日处理200KB小图1亿张；落地5+头部制造业客户，帮助客户存储成本降低30%以上，个人获2024年度公司金牌员工；
4. 开发的成本测算工具纳入公司标准化交付体系，输出压缩率/效率预估工具、存储方案成本和效益预估工具，提升产品私有化交付竞争力。

腾讯科技（深圳）有限公司 测试开发（全栈） 2018.04-2022.06

内容：

1. 构建腾讯云云服务器性能测评体系，GPU、ARM、虚拟化新机型从研发到上线的全流程性能测评，覆盖硬件基准、模拟真实业务、版本兼容性、极端压力场景四大类测试，输出可落地的性能调优方案与业务场景最佳实践；
2. 研发 TencentBench 标准化测评套件，完成 100+ 款行业通用性能测评工具的封装集成，支持套件跨物理机、虚拟机、容器环境批量部署，通过 YAML 实现测试场景零代码编排，把零散的测评工作统一成标准化流程；
3. 搭建性能基准数据管理与溯源平台，构建公司级标准化性能基线库，把每条基准数据和对应的测试负载、软硬件配置信息做关联绑定，实现性能数据可视化、测试报告自动生成、跨机型性能对比分析；
4. 搭建云服务器性能智能诊断引擎，基于机器学习实现性能异常自动检测、根因定位、趋势预警，把诊断能力嵌入 CI/CD 研发流水线，把性能测试提前到研发迭代环节，做到问题早发现早解决。

业绩：

1. 完成 13 款核心云服务器机型的全流程性能验证，做到机型上线零重大性能缺陷，相关客户性能投诉率降到 0.1% 以下，推动核心业务场景性能最高提升 25%。
2. 落地全自动化测评流水线，累计稳定执行 16 万次测评任务，覆盖腾讯云 90% 以上机型与 OS 迭代验证，单机型全量测试周期从 1 周压缩至 24 小时，整体测评效率提升 70% 以上，获得腾讯云2020年度效能优化之星。
3. 累计沉淀 300 万 + 条标准化性能基准数据，搭建起公司级性能数据底座，硬件选型的数据支撑率从 30% 提升到 100%，测试报告产出效率提升 95%。
4. 性能智能诊断能力与测试左移全面落地后，单性能问题定位时长缩短 90%，版本迭代中的性能劣化问题识别率达 100%，大幅降低了线上性能问题的复盘与修复成本。

深圳爱加密科技有限公司 iOS安全组长/架构集成 2015.08-2018.04

内容：

1. 负责 iOS 平台安全产品研发，重点推进代码混淆、安全防护 SDK、安全键盘、崩溃统计及安全检测引擎等核心产品落地，覆盖代码防护、异常识别全场景；
2. 深耕 iOS 安全攻防前沿技术，评估 Frida、MobSF 等工具及 Isolation Forest 算法的落地价值，打造并落地适配企业场景的安全攻防与检测方案；
3. 带领团队，统筹定制化需求交付，支撑市场端渗透测试、POC 验证及安全培训等相关工作；
4. 推进 CI/CD 流程搭建，开发自动化测试工具及可观测插件，完成 iOS 安全检测引擎架构集成，助力测试团队提升工作效率。

业绩：

1. 移动安全领域的产品特性在iOS平台上快速落地，为市场份额赢得先机，团队规模得到扩张；
2. 建成4~5人iOS安全团队，高效完成各类需求与市场支撑，客户反馈优良，期间无重大问题；
3. 研发iOS安全检测引擎及自动化工具，实现应用安全自动化审核，大幅提升检测效率、降低人工成本。

深圳市博安达信息技术股份有限公司 平台研发（全栈） 2013.11-2015.04

内容：

1. 参与环境监察移动执法系统 V3.0研发，负责自研中间件封装维护与前后端功能开发；
2. 基于Spring MVC + MyBatis、JSP + jQuery + EasyUI 技术栈，支撑终端实时查询企业环保全链路监管数据；
3. 负责自研消息队列、检索模块、配置中心、前端通用控件的封装与维护，解决政务场景离线数据同步、高效检索、动态配置等核心问题；
4. 独立开发现场取证、执法文书生成、在线监测、视频调取等核心功能，完成移动端 WebView 兼容适配；
5. 主导在线监测、跟踪、预警、考核模块的设计、开发与优化。

业绩：

1. 自研中间件支撑系统稳定运行，大幅提升组件复用率与研发效率；
2. 支撑龙岗、苏州园区、上海等多地区重点项目上线，实现执法全流程数字化。

深圳市茁壮网络股份有限公司 前端开发（实习） 2013.03-2013.11

内容：

参与公司 iPanel IPTV 智能终端系统前端开发与维护，负责界面实现、事件交互处理、视觉特效封装及多终端兼容性适配。

业绩：

1. 基于原生 JavaScript 与系统事件流驱动机制，处理机顶盒各类事件消息，保障界面交互与业务流程稳定运行；
2. 负责 IPTV 电视端 UI 界面的开发、维护与细节优化，确保界面展示正常、操作流畅；
3. 封装实现电视端焦点、转场等交互视觉特效，提升大屏端用户体验；
4. 完成 HTML5、CSS3 特性在机顶盒内置浏览器的兼容性适配，保障多机型渲染效果统一。

项目经历

AI驱动自动化测试体系建设 AI研发效能工程师 2025.05-2026.02

内容：

● 项目描述：Robot Framework 自动化测试体系，存在用例编写门槛高、版本迭代维护成本高、场景覆盖依赖人工经验三大核心痛点。通过大模型、RAG、智能体技术重构测试体系，打通从自然语言需求到测试执行、根因分析、缺陷闭环的全链路 AI 能力，实现测试效能跨越式提升。

技术栈：Robot Framework、LangChain、LangGraph、Milvus、FastAPI、Python、Jenkins、禅道、GitLab

● 核心工作

1. 专属 RAG 知识库架构设计：针对通用 RAG 单库检索易出现领域知识混淆、召回精准度不足的问题，设计分布式存储测试领域四层分域结构化知识库，拆分需求、用例、关键字、缺陷四大独立向量集合，完成产品10+版本全量测试资产的结构化解析与沉淀。同时优化 BM25 关键词检索、向量相似度检索、重排序的多级召回架构，实现测试全链路核心资产的精准召回，为大模型能力落地筑牢高质量数据底座，从根源解决大模型领域知识幻觉问题；
2. 测试智能体与工具链封装：针对大模型无法直接调用 RF 框架执行自动化测试的核心卡点，完成 1000+RF 关键字的标准化重构与分类，补充入参说明、使用示例、异常处理规则，形成大模型可理解、可稳定调用的标准化工具集。基于 LangGraph 构建测试全流程智能体，设计关键字匹配、参数填充、流程编排的可控执行链路，实现大模型对测试关键字的精准调用与自动化测试流程的自主编排；
3. 低幻觉可执行用例智能生成：针对大模型生成用例语法错误多、不符合领域规范、无法直接执行的行业痛点，设计实现 Few-Shot+RAG 融合的提示工程框架。基于自然语言测试需求，自动召回相似场景高质量用例、匹配的关键字示例注入 Prompt 上下文，用领域规范约束大模型输出，引导其生成结构完整、符合 RF 语法的可执行测试用例。同时自研 RF 用例预校验引擎，内置语法、入参、环境依赖自动校验能力，对不合格用例自动触发大模型二次修正，大幅降低生成内容的幻觉率；
4. AI 驱动的测试全流程闭环设计：打通体系与 CI/CD、代码库、缺陷管理系统的深度集成，设计 AI 驱动的全自动化测试闭环：代码提交后自动识别变更模块，触发对应模块的精准回归测试；针对执行失败的用例，自动拉取测试日志、集群运行数据，结合 RAG 召回历史相似缺陷，完成自动根因分析、生成修复建议，并同步输出标准化缺陷单自动指派负责人，实现测试全流程的无人值守智能化管控。

业绩：

1. 新增需求用例交付周期从 3 天压缩至小时级，彻底降低用例编写门槛，无需精通 RF 语法即可生成合规可执行用例；
2. 版本迭代带来的用例维护人力占比从 40% 降至 15% 以内，大幅释放测试团队人力；
3. 解决人工经验依赖的场景覆盖短板，分布式存储集群级复杂场景测试覆盖度提升 30% 以上。

Cursor内部赋能与大模型技术分享　AI研发效能工程师　2025.09-2026.01

内容：

● 项目描述：为企业内部技术团队开展常态化 AI 技术系列分享，共12次周四大讲堂2小时分享。结合团队技术需求与 AI 落地痛点，规划分享主题，内容覆盖 Cursor项目演示、大模型技术栈、工程化落地等核心方向，同步前沿 AI 技术实践与实战踩坑经验，帮助团队降低技术入门门槛，落地 AI 研发提效方案。

● 核心工作

1. AI 编程工具落地与团队赋能：完成Cursor AI 编程工具的选型、验证与落地规范制定，梳理 Vibe Coding 工作流，编写标准化教程、使用手册与最佳实践文档，面向全研发团队开展专项培训与答疑，推动 AI 编程工具在日常开发、Code Review、调试优化全流程规模化使用。
2. AI 工程化项目演示：基于 LangChain/LangGraph/AutoGen 搭建多 Agent 协作与多轮对话流程，使用 LlamaIndex 构建 RAG + 混合检索 + 知识图谱增强方案；通过 FastAPI、Docker、K8s 完成服务封装与容器编排，集成 Prometheus 监控与链路追踪，实现高可用工业级 AI 系统部署。
3. 大模型高效微调与轻量化部署：采用 LoRA/QLoRA 等 PEFT 技术对 ChatGLM3、DeepSeek 等模型进行垂直领域微调，实践 GPTQ/AWQ 量化与知识蒸馏，降低推理资源消耗；在华为昇腾平台、ModelArts 完成微调与边云协同部署，演示国产化硬件环境。
4. AI 技术体系沉淀与内部分享：系统性整理大模型微调、RAG、多 Agent、私有化部署等核心技术栈，输出可复用方案与实践案例，面向公司研发、测试团队开展技术分享，推动 AI 知识在内部流转复用。

业绩：

1. 完成 Cursor 在研发团队的规模化落地，输出完整培训与规范体系，团队整体编码效率显著提升，新人上手速度与代码规范性同步优化。
2. 沉淀一套可复用的 AI 全栈技术方案与培训材料，通过内部分享完成技术赋能，为公司后续 AI 项目落地提供直接参考与人才基础。

华为HCIE-AI解决方案架构师认证 AI解决方案架构师 2025.07-2025.12

● 大模型全栈技术体系：通过系统学习和实战训练，全面掌握大语言模型、多模态模型的算法架构、训练与微调(如SFT、LoRA)、模型压缩与部署(如ModelSlim、vLLM)、以及提示工程、Agent开发等核心应用范式。深刻理解从业务场景识别到模型选型、安全治理的端到端应用流程。

● 昇腾平台进行大模型训练与优化：深入理解华为昇腾(Ascend)大模型解决方案，包括CANN异构计算架构、MindFormers开发套件等工具链。掌握数据并行、张量并行、流水线并行等分布式训练策略，能够针对大模型的算力、通信与内存挑战进行性能调优与算子开发，实现高效训练与部署。

● 智算中心级AI解决方案架构：理解AI算力底座的关键构成，能够基于昇腾硬件(如Atlas服务器)与MindX系列软件栈进行方案设计。熟悉智算中心在基础设施(供电/制冷/液冷)、分布式存储(如OceanStor Pacific)、高速无损网络等方面的规划与选型，确保解决方案的高性能、高可靠与高能效。

● 从技术到行业应用的全链路思维：结合行业模型选型(如LLaMA、ChatGLM)、数据工程、以及RAG、向量数据库等增强技术，具备将大模型能力适配金融、政务、制造等具体业务场景的架构设计能力。能够综合考虑算力成本、模型性能、安全合规与业务价值，设计可行的AI落地方案。

iData智能运维问答系统 AI全栈应用开发 2023.03-2025.04

内容:

● 项目描述：项目初始目标为解决分布式存储私有化交付场景下的告警运维痛点：原有告警体系仅能推送故障现象，无法实现精细化定位、日志溯源、根因分析，一线运维人员处理一条告警需平均翻阅4份产品文档、排查5个模块日志，故障定位时长超2小时，问题解决效率极低。2023年大模型技术爆发，公司启动AI+存储战略，项目以告警根因分析为切入点，按周迭代、月度发版的节奏，逐步完成从专属告警问答->通用私有化问答系统->RAG体系深度优化->多角色权限隔离->智能Agent能力建设->PB级多模态检索->全栈国产化适配的全链路演进，最终打造一款可规模化落地的私有化智能运维助手，解决运维痛点的同时打造产品AI差异化竞争力。

● 技术栈：ChatGLM3-6B/Baichuan2-7B/Qwen-72B/DeepSeek开源大模型、Milvus 2.3向量数据库、BGE-large-zh-v1.5嵌入模型、BGE-reranker-large重排序模型、AltCLIP多模态嵌入模型、LangChain、LangGraph、FastAPI、Unstructured文档解析工具、Fluentd日志采集工具、Kubernetes、华为Atlas 300I Pro、MindIE推理引擎、MySQL

● 核心工作

1. 告警精细化根因分析与基础问答能力搭建：完成分布式存储全量告警场景的系统性梳理，覆盖1000+告警规则的处理SOP、故障定位指南、修复指引；对接存储系统核心模块日志、K8s各组件日志、服务器硬件监控日志三大数据源，基于Fluentd实现日志的实时采集、结构化解析与告警事件关联映射，构建告警-日志-解决方案的全链路关联体系，完成MVP版本告警专属问答助手开发，实现告警事件的自动溯源与根因分析。

2. RAG检索增强与知识库分域治理：针对基础问答版本检索准确率低、幻觉率高的问题，从0到1搭建私有化RAG全链路架构；设计三层知识库分域架构，按通用领域知识（分布式存储/K8s/Linux通用知识）、版本专属产品文档（产品说明书/管理员手册/技术白皮书，与产品发版节奏同步更新）、客户定制化知识库做物理隔离与独立向量化；针对分布式存储CLI命令、API接口、故障SOP的文档特性，优化“标题层级+语义边界+命令完整性”的文档分块策略，配合Unstructured实现多格式文档统一解析，设计“BM25关键词检索+向量相似度检索”的混合检索架构，配合重排序模型优化检索效果。

3. 多租户多角色权限隔离：针对私有化交付场景的合规要求，设计“向量库物理分片+检索层元数据过滤+问答层内容拦截”的三级权限管控方案；基于RBAC模型定义普通用户、存储用户、系统管理员三级角色，为每个角色配置对应的知识库访问范围、检索定向规则、问答内容权限，实现不同角色仅能访问对应权限的文档内容与问答能力，同时满足多租户之间的知识库数据完全隔离。

4. 跨系统协同的智能体Agent能力建设：针对客户需求升级，需将问答能力开放给上下游系统（如制造业AI质检系统）、实现自动化故障修复的需求，基于LangGraph设计多节点智能体状态机，拆分需求解析、工具调用、流程编排、结果校验、异常重试5个核心节点；封装日志查询、集群巡检、告警修复、配置核对、命令执行6大类工具集，实现多步骤的自动化故障排查、根因分析、修复执行全流程闭环，解决单轮问答无法完成复杂运维任务的痛点。

5. PB级数据场景下的多模态检索能力落地：针对客户提出的架构图、故障截图、操作手册扫描件、办公文档等非结构化数据的检索需求，传统ES检索无法满足语义匹配需求，搭建多模态检索体系；基于AltCLIP多模态嵌入模型，实现图片、文本、PDF、

Word等多格式文件的统一向量化，优化向量索引结构与分片策略，适配PB级存储集群的海量非结构化数据检索场景，解决多模态数据的精准检索难题。

6. 全栈国产化适配与规模化落地优化：针对客户侧无GPU环境的部署痛点，完成ChatGLM3-6B、Baichuan2-7B、Qwen-72B等主流大模型在华为Atlas 300I Pro NPU与MindIE推理引擎的全栈适配，优化算子调度、批处理策略与上下文窗口管理，同时完成CPU/GPU/NPU多环境兼容部署适配，实现无GPU环境下的私有化落地，输出标准化部署最佳实践白皮书。

业绩：

1. 基于 k-means 算法的图片压缩率预测模型，预测准确率达92% 以上，帮助客户优化压缩策略，在保证画质的前提下提升压缩效率35%，降低存储传输成本28%。

2. 搭建的办公文件大数据预处理标准化流程，覆盖10 + 类办公文档格式，将人工规整效率提升60%，数据冗余率降低40%，为后续 AI 分析与检索奠定高质量数据基础。

3. 完成大 / 小文件性能基准测试，输出8 份标准化性能对比报告，成为 3 家行业客户存储架构升级的核心参考依据，推动客户存储资源利用率提升30%。

4. 输出的 15 份定制化解决方案成功支撑 6 大重点项目落地，客户项目验收通过率100%，客户满意度达95% 以上；沉淀的最佳实践与工具包，将同类项目方案交付周期缩短50%，赋能团队高效响应新客户需求。

5. 研发的压缩率 / 效率预测工具、存储成本效益预估工具，已嵌入公司标准化交付体系，累计为 12 家客户提供方案测算服务，帮助客户精准评估存储成本，平均降低方案选型试错成本25%。

NPU图片智能无损压缩　AI全栈应用开发　2024.03-2024.12

内容：

● 项目描述：制造业、安防等行业客户存在PB级非结构化图片数据存储需求，传统图片压缩方案存在三大核心痛点：一是通用压缩方案无法兼顾压缩率与视觉效果，存储成本居高不下；二是海量小图片压缩处理效率低，单张图片处理耗时超300ms，无法满足业务峰值处理需求；三是客户侧国产化算力资源（华为Atlas NPU）闲置，CPU算力成为压缩处理的核心瓶颈。为解决客户痛点，同时打造分布式存储产品的增值服务能力，启动NPU加速的智能图片压缩系统研发项目。

● 技术栈：k-means聚类算法、Python、Golang、Kubernetes、Kafka、Atlas 300I Pro推理卡、Ceph RGW、OpenCV

● 核心工作

1. 设计智能压缩核心算法，基于k-means聚类算法对图片类型、分辨率、纹理特征、色彩空间进行无监督分类，构建压缩率与处理效率双目标预测模型，针对不同特征的图片自动匹配最优压缩参数与算法组合，在视觉无损的前提下最大化压缩率。

2. 设计分布式处理架构，拆分数据拉取、特征提取、算法决策、压缩执行、数据回写五大模块，基于Golang开发压缩服务SDK，完成与杉岩分布式存储系统RGW网关的深度对接，实现存储数据的就近处理，避免跨节点数据拉取带来的带宽损耗。

3. 完成国产化NPU适配与算力卸载，将图片特征提取、模型推理核心环节从CPU卸载至华为Atlas 300I Pro NPU，完成算子优化与调度策略调整，实现CPU/NPU异构算力协同。

4. 开展全链路性能调优，针对跨NUMA内存访问、RGW跨节点带宽瓶颈、压缩实例并发调度等问题，完成Pod NUMA亲和性配置、压缩/解压实例数配比优化、CPU/内存资源阈值调整、压缩线程数与协程调度策略优化。

业绩：

1. 在保证图片视觉无损的前提下，压缩率较行业通用JPEG压缩方案提升12%，帮助客户PB级图片数据存储成本降低30%以上，落地5+头部制造业客户。

2. 实现了压缩服务与存储系统的深度融合，数据处理链路缩短60%，避免了跨节点带宽瓶颈，单集群带宽利用率从35%提升至80%以上。

3. 核心推理环节处理耗时降低80%，CPU算力占用降低70%，盘活了客户侧闲置的国产化算力资源，解决了CPU算力瓶颈问题。

4. 单张200KB JPG图片压缩处理耗时从300ms缩短至10ms以内，处理效率提升30倍；15节点集群单日可处理200KB规格JPG小图片1亿张，完全满足客户业务峰值处理需求，个人凭借该项目成果获得2024年度公司金牌员工荣誉。

DevOps云原生体系建设　DevOps工程师　2022.06-2023.03

内容：

● 技术栈：Jenkins、Kubernetes、Docker、Helm、Kubeadm、夜莺N9E、Prometheus、Grafana、Robot Framework、Calico

● 核心工作

1. 构建容器化编译体系，基于JenkinsFile实现流水线即代码，定制适配x86/ARM双架构的分布式存储编译基础镜像，集成全量编译依赖，内嵌VS Code Server实现WebIDE交互式编译调试，支持多人并行编译、环境快照留存、断点续编。

2. 开发集群一键部署工具与iData系列Helm Chart插件，基于Kubeadm封装集群部署Operator，整合Calico网络、LocalPV存储、Metrics监控等核心组件，实现裸金属服务器初始化、K8s集群搭建、分布式存储集群部署的全流程自动化。

3. 重构全栈监控告警体系，基于K8s实现夜莺N9E平台容器化部署，完成物理服务器、K8s集群、分布式存储集群300+项指标的全维度采集，设计分级告警规则引擎与降噪策略，完成原有200+Python脚本监控项的标准化迁移。

4. 推动ATDD模式落地，基于Robot Framework封装Shell/API/CLI三级关键字库，开发测试执行编排引擎，实现测试用例的自动调度、并行执行、报告自动生成，打通与Jenkins流水线的集成，实现代码提交自动触发回归测试。

业绩：

1. 彻底解决了多模块编译环境不一致的痛点，编译任务稳定性从92%提升至99.5%，编译环境交付周期从3个工作日缩短至分钟级，支撑10+核心模块每日数百次集成编译任务，研发编译环节效率提升80%以上。

2. 集群交付部署周期从3人天缩短至2小时内，交付效率提升90%以上，人工操作出错率从15%降至0，同时完成了国产化服务器与操作系统的适配，大幅提升了产品私有化交付能力。

3. 实现告警分级、降噪、闭环全流程管理，告警误报率降低80%，告警响应时长从小时级缩短至分钟级，线上故障发现率从75%提升至100%，运维体系稳定性大幅提升。

4. 封装核心测试关键字1000+，覆盖全量核心功能测试场景，测试执行效率提升70%，全量回归测试周期从3天缩短至8小时，支撑研发流程完成从瀑布式到敏捷双周迭代的转型，整体研发交付效率提升60%以上。

云服务器性能智能诊断引擎　AI应用开发　2021.04-2022.06

内容：

● 项目描述：传统服务器性能问题诊断高度依赖资深工程师的人工经验，排障周期长、小样本故障定位准确率低，线上性能问题无法快速闭环，既影响客户体验，也占用了大量研发资源。我基于前面沉淀的性能基准数据与全链路元数据，主导搭建性能智能诊断引擎，实现异常检测、根因定位、优化建议的端到端自动化，降低排障门槛，提升问题解决效率。

● 技术栈：Python/Scikit-learn、K-Means/KNN/LightGBM/XGBoost/孤立森林/ARIMA、Golang/Gin、特征工程、模型工程化。

● 核心工作

1. 全流程特征工程与样本库建设：基于历史测评数据、300万+基准值与全链路元数据，完成数据清洗与标准化处理，提取硬件/系统/负载/性能四大类200+维核心特征，构建标准化特征向量体系；标注10万+条故障样本，覆盖12大类核心性能异常场景，搭建特征库并完成特征筛选与降维，通过增量学习持续迭代特征权重；

2. 核心诊断模型设计与落地：结合性能诊断场景对可解释性、稳定性的要求，选择经典机器学习算法搭建核心引擎，避免复杂深度学习模型的黑盒问题。其中，通过K-Means完成基准值聚类计算与性能梯队划分，生成动态基准阈值；基于LightGBM/XGBoost搭建性能基线预测模型；基于孤立森林实现无监督异常检测；基于KNN优化小样本故障场景的根因定位；基于ARIMA实现时序性能趋势预测，提前预警性能衰减、内存泄漏等隐性风险；

3. 工程化落地与平台集成：通过Golang/Gin将训练好的模型封装为高并发RESTful API，开发可视化诊断界面，深度集成至TencentBench平台，打通"压测-异常检测-根因诊断-优化"全流程，实现性能问题的自动化、标准化诊断。

业绩：

1. 智能诊断引擎覆盖80%以上核心性能异常场景，整体定位准确率达92%，小样本场景准确率从65%提升至92%，问题定位时长从2小时缩短至10分钟，排障效率提升90%；

2. 累计辅助定位40+项核心性能隐患，推动业务模块性能平均提升25%，成为服务器版本迭代、故障复盘的核心工具；

3. 诊断能力接入CI/CD流水线后，版本迭代性能劣化问题发现率从70%提升至100%，实现性能问题在研发阶段闭环，大幅减少了线上问题的复盘与修复成本。

云驭性能基线与全链路溯源平台　全栈开发　2020.04-2022.06

内容：

● 项目描述：测评套件规模化落地后，产生了海量的测评数据，但存在数据分散无统一管理、性能基准无标准化沉淀、测试结果无法全链路溯源、跨机型对标分析效率低的问题，导致硬件选型、版本迭代没有统一的量化依据，决策试错成本高。我主导搭建性能基准数据管理平台，作为测评体系的核心数据底座，实现测评数据的资产化管理，为产品决策、性能评估提供统一的数据支撑。

● 技术栈：Golang/Gin、React/TypeScript/ECharts、PostgreSQL、腾讯云时序数据库CTSDB、分布式对象存储、元数据管理、自动化报告引擎。

● 核心工作

1. 设计"数据采集层-数据湖治理层-基准计算引擎层-对标服务层-可视化应用层"5层解耦云原生架构，采用Golang/Gin搭建高并发后端服务，支撑十万级实例测评数据的高吞吐写入、低延迟查询，满足大规模流水线任务的并发数据处理需求；

2. 落地分层存储架构，适配累计PB级的时序性能数据、压测日志与报告文件：采用腾讯云时序数据库CTSDB存储高频性能时序指标，PostgreSQL管理300万+条标准化性能基准元数据、告警规则与用户配置，分布式对象存储归档冷数据、测评日志与报告文件；通过冷热数据分离策略，兼顾查询效率与存储成本；

3. 构建公司级标准化性能基准体系，承接全量测评数据，沉淀300万+条标准化性能基准值，覆盖全维度测评指标、核心机型与主流业务场景；设计标准化元数据结构，实现每条基准值与测试负载模型、并发策略、IaaS资源配置、OS版本、内核参数、虚拟化配置等全链路信息的强关联，彻底解决了测试结果不可复现、问题无法溯源的问题；

4. 研发自动化报告引擎，支持单机型测评报告、版本迭代对比报告、竞品对标报告的自动生成与一键导出；基于React/TypeScript/ECharts搭建多维度可视化模块，实现性能基线天梯图、趋势对比、异常溯源的可视化展示，针对百万级数据渲染做了懒加载与分片优化，保障页面流畅交互，为硬件选型、方案推荐提供直观的量化支撑。

业绩：

1. 打造腾讯内部唯一的服务器性能基准数据管理平台，沉淀300万+条标准化性能基准值，覆盖腾讯云90%以上在售云服务器机型，成为公司硬件选型、版本迭代、性能测评的唯一官方数据标准；

2. 自动化报告引擎落地后，单份报告产出时长从4小时压缩至10分钟，人工成本降低95%，累计自动生成各类报告5万+份；后端服务支撑万级并发查询，数据查询延迟控制在200ms内，稳定运行2年，全年故障率低于0.5%；

3. 性能基准体系落地后，硬件选型数据支撑率从30%提升至100%，版本迭代性能劣化识别准确率达98%，大幅降低了产品决策的试错成本，同时为后续智能诊断引擎提供了高质量的基准数据与全链路元数据支撑。

TencentBench测评套件与DevOps体系建设　测试开发　2019.02-2021.07

内容：

● 项目背景：腾讯云服务器机型快速迭代，传统人工测试、碎片化工具的模式，已经无法支撑规模化的机型验证与研发自测需求，存在测试效率低、人工成本高、测评结果不统一的问题。对标主流基准测试套件，研发TencentBench标准化测评套件与自动化体系，实现测评流程的标准化、自动化，提升研发测试效率，降低人工成本。

● 技术栈：Python/Shell/YAML、Ansible批量编排、CI/CD插件开发、测评工具集成、Prometheus/Grafana监控对接。

● 核心工作

1. 设计测评引擎+编排层+数据层+集成层，四层解耦架构，统一测评接口与数据规范，保障测评结果可复现、可对比，解决了多场景测评适配难、数据不通的问题，实现了不同机型、不同场景的公平度量；

2. 主导研发标准化测评套件，完成100+款行业通用测评工具、主流业务场景仿真模型的封装集成，覆盖CPU/内存/磁盘/网络/AI算力全维度测评，填补了公司内部云服务器标准化测评的空白；

3. 创新实现YAML零代码场景编排，支持测试人员快速定制测评场景、并发策略与监控指标，大幅降低工具使用门槛；自研CI流水线专属SDK，实现研发流程一键接入测评能力，把性能测试提前到实验室和研发迭代环节，做到测试左移；

4. 基于Ansible实现测评套件跨物理机/虚拟机/容器环境的批量部署与版本运维，保障全平台测评环境一致性，杜绝环境差异导致的结果偏差；搭建自动化报告生成与异常预警模块，自动完成数据汇总、基准对比与初步定位，替代人工分析。

业绩：

1. 打造公司内部首款标准化云服务器测评套件，实现测评从经验化到标准化的转型，单机型全维度测试周期从1周天压缩至24小时，测评效率提升70%以上；
2. 零代码编排+CI集成方案落地后，业务团队自助接入效率提升90%，研发自测普及率提升50%，人工干预成本降低90%；流水线累计稳定执行16万次测评任务，覆盖腾讯云90%以上机型与OS迭代验证；
3. 性能问题初步排查时长缩短60%，跨团队协同效率提升40%，凭借显著的提效降本成果，获腾讯云2020年度效能优化之星，套件成为公司云性能评估的唯一官方标准工具。

虚拟化新机型性能专项　性能测试　2018.04-2021.03

内容：

● 项目背景：腾讯云GPU、ARM、虚拟化新机型迭代节奏快，人工测试覆盖不全、和线上业务场景脱节，频繁出现上线后性能不达标、客户投诉的问题，同时冗长的测试周期也拖慢了机型上市节奏。我全权负责新机型从研发到上市的全流程性能验证，搭建可复用的标准化测试体系，保障机型零重大性能缺陷上线，同时压缩测试周期、提升交付效率。
● 技术栈：UnixBench/Sysbench/MLPerf/TensorFlow Benchmark等性能测试工具、KVM/QEMU虚拟化、Prometheus/Grafana监控可视化、Perf/火焰图性能分析。
● 核心工作
1. 搭建多维度标准化性能测试体系，制定硬件基准、业务复合负载、版本兼容性、极端场景四大类测试规范，落地MLPerf等行业通用AI性能测试标准，覆盖通用计算、AI训练/推理、大数据等主流业务场景，解决了传统测试覆盖不全、结果不可靠的问题；
2. 针对Tesla系列GPU机型、ARM架构服务器、KVM虚拟化新规格虚拟机，设计专项测试用例，完成内核、驱动、固件的交叉兼容性验证，覆盖容器、vGPU、裸金属全部署形态，不留测试盲区；
3. 搭建Nginx、ETCD、Hadoop、Codis全栈业务仿真环境，模拟线上真实负载，构建轻/中/重三级业务性能模型，实现硬件性能与业务场景的联动验证，解决了测试与业务脱节的核心问题；
4. 通过Prometheus毫秒级监控、Perf火焰图定位全链路性能瓶颈，输出CPU绑核、内核参数、IO调度算法、虚拟化驱动、GPU算力分配等维度的系统调优方案，通过对比压测闭环验证优化效果，从根源解决性能问题；
5. 基于Prometheus+Grafana搭建性能指标可视化看板，实现多机型、多版本、多场景的性能对标数据实时展示，自动生成标准化可视化对标报告，替代人工汇总制表，大幅提升测试结果的交付效率。

业绩：

1. 主导13款核心新机型、10+项核心特性的全周期性能验证，实现零重大性能缺陷上线，覆盖腾讯云TOP20 AI大客户，客户性能投诉率降至0.1%以下，AI业务相关性能投诉降幅达80%；
2. 累计排查20+项性能隐患，攻克3项核心性能抖动问题，推动磁盘IO、网络虚拟化层性能提升25%，AI训练时长缩短30%、推理延迟降低20%；
3. 输出10+份性能白皮书与5份业务最佳实践文档，搭建初代性能基准库，新机型落地效率提升30%，单场景测试周期从2天压缩至4小时。

iOS应用安全威胁感知平台　检测引擎/架构集成　2015.08-2018.03

● 自动化测试工具：基于越狱设备构建自动化 UI 遍历测试工具，用于采集动态行为数据以支撑安全检测。参考 AppCrawler 实现应用自动启动、UI 智能遍历、页面跳转控制与手势模拟，支持自动分析网络请求、加解密行为、异常日志及崩溃信息，可适配音视频播放器等复杂场景。通过自动化遍历生成大量运行时行为数据，为动态分析与异常检测提供真实、充足的样本输入，提升引擎对隐私窃取、恶意行为等风险的识别能力。
● iOS 安全检测引擎：设计并实现集静态检测、动态分析、异常识别于一体的 iOS 应用安全检测引擎。静态分析基于Mach-O解析、权限检测、特征匹配等核心技术，参考 MobSF 原理实现应用基础信息、行为特征、风险特征、安全防护及应用漏洞等多维度检测。预研越狱环境下的动态分析技术，使用 Frida、Needle、Introspy、Snoop-it 搭建运行时行为采集与 Hook 分析引擎。通过轻量级 Spark 完成静态 + 动态特征融合，基于 scikit-learn 在技术预研阶段落地 Isolation Forest 无监督异常检测算法。方案支撑企业应用上架自动化安全审核，能够有效识别隐私窃取、仿冒、二次打包等未知威胁，显著提升检测效率并降低人工审核成本。

● 架构集成：参考 Android 安全检测体系，基于 Spring Boot + Flask 实现后端服务，采用 Redis + MySQL 完成任务调度与特征存储，使用 Socket + HTTP 实现 macOS 静态引擎、越狱设备动态集群、Spark 特征处理模块的跨节点通信。设计并落地静态、动态、机器学习三大引擎统一调度流程，完成任务分发、设备集群管理、数据标准化、结果聚合上报等模块对接，构建高可用、自动化的企业 iOS 应用安全审核架构。

iOS安全防护产品 iOS安全研发 2015.08-2016.08

● 代码混淆：防止应用代码被破壳后逆向分析，基于宏定义的非侵入式混淆方案，通过Mac工具自动生成混淆头文件，在项目PCH文件中引用，从而安全简便地实现类名、方法名及属性名的混淆；

● 安全防护SDK：防止应用被重签名、动态调试及运行环境攻击，通过本地签名校验、反反调试防护与越狱插件检测等功能，提供检测、感知、防护三类验证结果；

● 安全键盘SDK：针对系统键盘存在的回显、截图、缓存等问题，提供一套安全键盘SDK的解决方案，支持国密2算法以及一次一密；

● 崩溃统计SDK：出于安全需求分析crash日志，其难点在于符号表的解析，调研选取Facebook提供的otosl工具作为解析器，在Centos7、Ubuntu14服务器上成功编译、部署。

教育经历

夏威夷太平洋大学 硕士 人工智能 2025-2027

武汉软件工程职业学院 大专 软件工程 2010-2013

资格证书

工信部-深度学习算法研发工程师-高级 PMP项目管理认证 华为HCIE-AI解决方案架构师-专家
智谱AI-大模型应用开发人才认证证书